TALLER 1: ANÁLISIS PREDICTIVO Y APRENDIZAJE ESTADÍSTICO
CASO DE ESTUDIO: ADVERTISING DATA

PRESENTADO POR:

ANA MARIA BARACALDO. Cód: 118633

DIANA CAROLINA CAMELO O. Cód: 24766

ANDRÉS FONSECA RODRÍGUEZ Cód: 81796

CARLOS ALBERTO CASTELLANOS ACUÑA Cód. 119823

PRESENTADO A

DOC. FREDY ALEXANDER ORJUELA LOPEZ SISTEMAS AVANZADOS DE PRODUCCIÓN

UNIVERSIDAD ECCI INGENIERÍA INDUSTRIAL

2026

RESUMEN (ABSTRACT)

El presente informe analiza la relación entre la inversión publicitaria en **TV, Radio y Periódico**, así como su efecto en el nivel de ventas, utilizando técnicas de estadística descriptiva y modelos de regresión; el estudio realizado se divide en 2 fases: 1) Análisis exploratorio de datos y 2) Desarrollo de un modelo predictivo.

Los resultados obtenidos demuestran que la publicidad en **TV** tiene la correlación más fuerte, positiva con las ventas (r= 0.78), en segundo lugar, se encuentra la **Radio** con una asociación moderada (r = 0.58).

Por el contrario, la inversión en **periódicos** mostró una relación débil (r = 0.23), así como una contribución nula en el modelo múltiple, ya que el modelo de regresión lineal múltiple obtenido presenta un alto poder explicativo, con un **R^2 de 0.8972**, indicando que las variables analizadas explican el **89.72%** de la variabilidad en las ventas.

De acuerdo con el análisis, la TV es el principal motor de ventas, sin embargo, el análisis de coeficientes sugiere que la **radio** posee un impacto marginal superior por unidad invertida (0.1885 frente a 0.0458 de TV).

El cálculo de los parámetros se validó mediante álgebra matricial, obteniendo la ecuación estimada y^ = 0.8 + 1.6x para el ejercicio técnico propuesto, por lo tanto, se concluye que la inversión debe optimizarse priorizando los medios de TV y Radio, dada la ineficacia estadística del canal impreso.

INTRODUCCIÓN

El presente informe se centra en el estudio de la elasticidad de la demanda, tomando en cuenta su relación entre la inversión publicitaria y el volumen de ventas; este análisis cobra importancia en el ambiente empresarial competitivo, ya que comprender cómo impacta cada canal de comunicación en el comportamiento del consumidor es fundamental para la optimización de los recursos en los procesos de ingeniería industrial.

El análisis se desarrolla en dos etapas técnicas:

Etapa 1: Se realiza una caracterización estadística descriptiva y exploratoria de las variables (canales) de TV, Radio y Periódico.

Etapa 2: Se implementa un modelo de regresión lineal múltiple para cuantificar el efecto marginal de cada medio y determinar la capacidad explicativa del conjunto de inversiones sobre las ventas totales.

Con la realización de este estudio, se busca identificar cuáles son los canales que generan un impacto relevante y cuáles carecen de poder explicativo, esto a su vez, proporciona una base técnica para la toma de decisiones estratégicas en los sistemas avanzados de producción.

METODÓLOGÍA

Para la realización de este informe se utilizaron los enfoques cuantitativo y analítico, a través de tres fases principales para garantizar la veracidad de las conclusiones sobre la elasticidad de la demanda:

1. **Análisis Exploratorio de Datos:** Se calcularon medidas de tendencia central (media y mediana) y de dispersión (desviación estándar) para las variables de inversión (TV, Radio, Periódico) y la variable de respuesta (Ventas). Y se analizó la asimetría para comprender la distribución de los datos.

2. **Análisis de Correlación:** Se utilizó el **Coeficiente de Correlación de Pearson** para cuantificar la fuerza, así mismo la dirección de la relación lineal entre cada medio publicitario y las ventas, permitiendo identificar con antelación cuáles canales tienen mayor impacto.

3. **Modelado por Regresión Lineal Múltiple:** Se construyó un modelo matemático para estimar el efecto conjunto de las variables independientes. Para llevar a cabo este método se llevaron a cabo tres procesos importantes:
   - **Estimación de Parámetros:** Uso del método de **Mínimos Cuadrados Ordinarios (MCO)**.
   - **Validación Matricial:** Cálculo manual de los coeficientes mediante álgebra de matrices (operaciones de transpuesta, producto y matriz inversa) para verificar la precisión de los resultados obtenidos computacionalmente.
   - **Evaluación de Ajuste:** Determinación del coeficiente de determinación **R^2** para medir la capacidad predictiva y el nivel de confianza del modelo.

Con la utilización de este método, se logró no solo describir el comportamiento histórico, sino también generar una ecuación de predicción confiable para la toma de decisiones estratégicas en la inversión de mercadeo.

Fase 1: Estadística Descriptiva y Análisis Exploratorio

📊 Medidas de Tendencia Central y Dispersión

Variable	Media	Mediana	Desv. Estándar	Mínimo	Máximo	Asimetría (Skewness)	Curtosis
TV	147.04	149.75	85.85	0.70	296.40	-0.07	-1.23
Radio	23.26	22.90	14.85	0.00	49.60	0.09	-1.26
Newspaper	30.55	25.75	21.78	0.30	114.00	0.89	0.65
Sales	14.02	12.90	5.22	1.60	27.00	0.41	-0.41

Tabla [1] Esta tabla muestra las medidas de tendencia central y dispersión para las variables independientes y las variables independientes y la variable Sales dependiente.

2. Análisis de Distribución y Atípicos

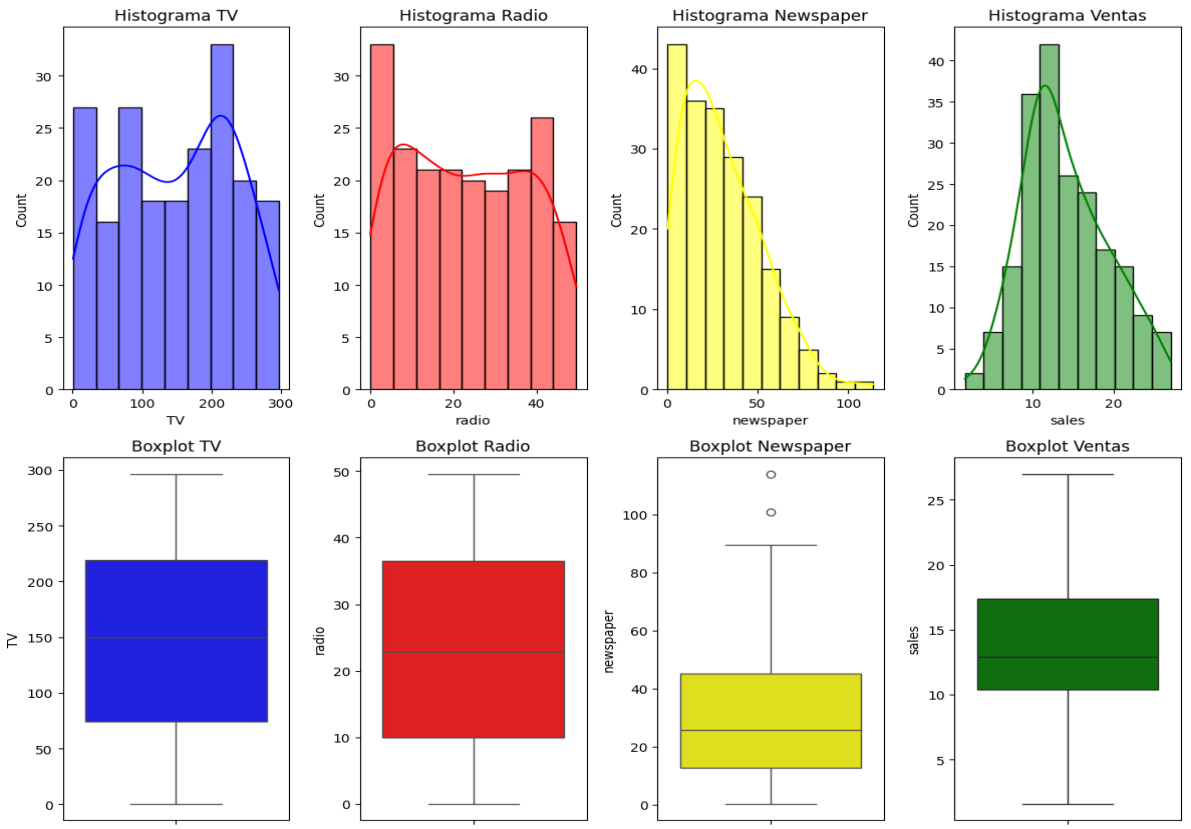

Figura [1]: En la parte superior de la gráfica encontramos los histogramas de las variables que son de TV, Radio, Newspaper,

3. Evaluación de Asociación: Calcule y presente las matrices de correlación de Pearson y Spearman.

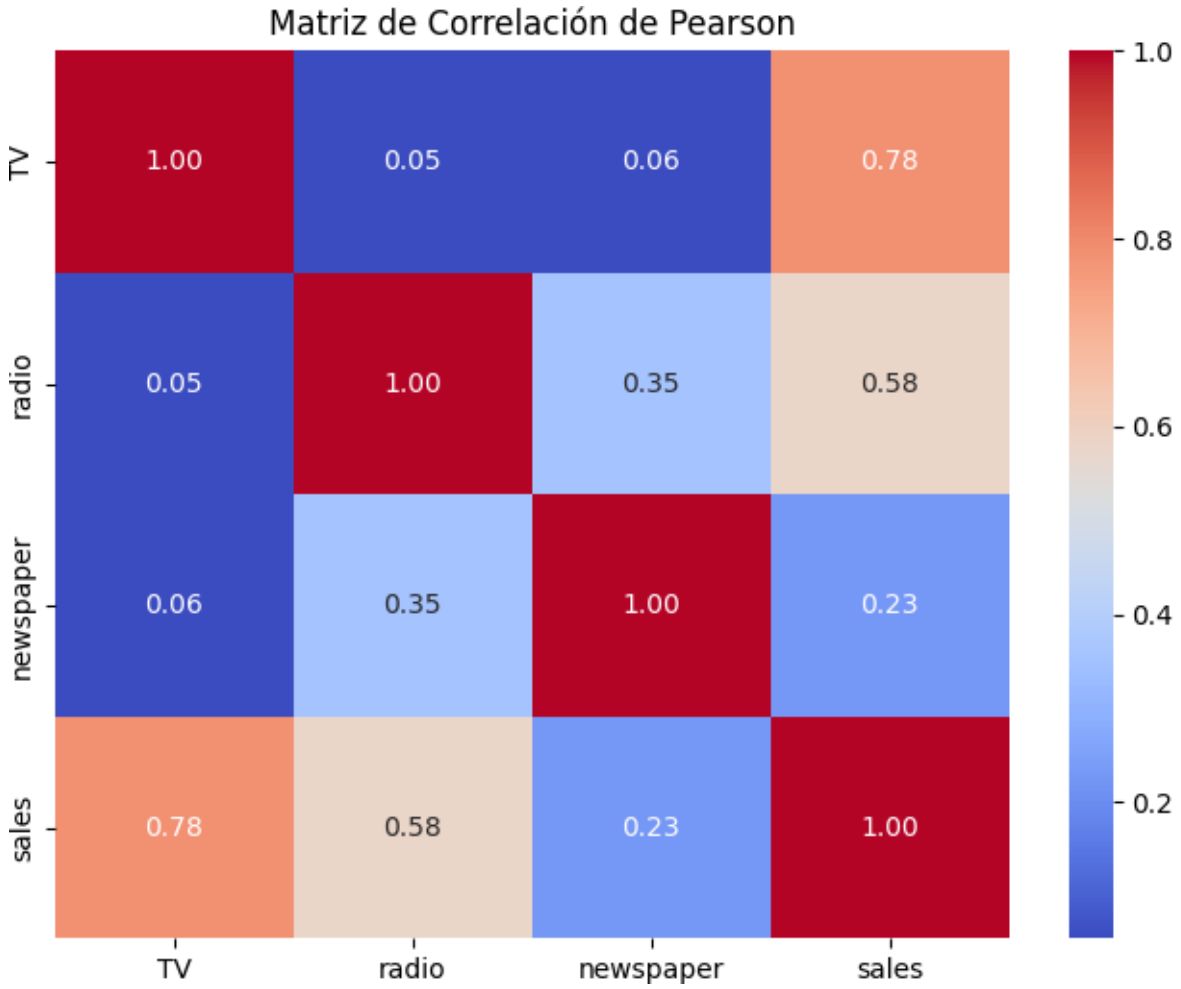

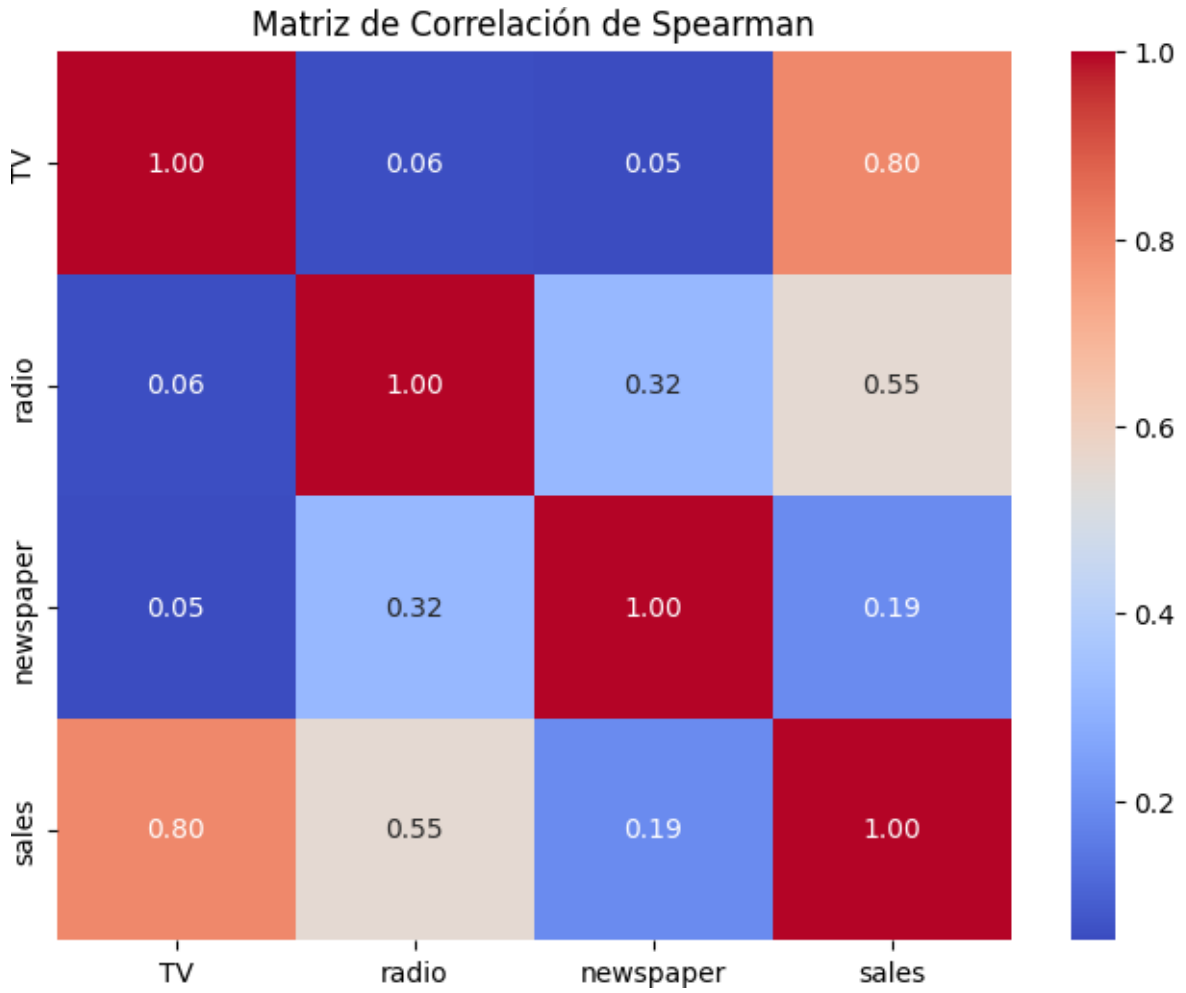

Se evidencia una **correlación lineal positiva fuerte** entre la inversión en TV y las ventas, lo que indica una asociación directa significativa; además, el coeficiente de Spearman confirma una **relación monotónica positiva fuerte**. (Pearson r = 0.78; Spearman ρ = 0.80), Se observa una **correlación lineal positiva moderada** entre la inversión en radio y las ventas, evidenciando una asociación directa de magnitud intermedia, consistente con una **relación monotónica positiva moderada**. (r = 0.58; ρ = 0.55), Existe una **correlación lineal positiva débil** entre la inversión en periódico y las ventas, lo que sugiere una asociación directa de baja intensidad; el coeficiente de Spearman confirma una **relación monotónica positiva débil**. (r = 0.23; ρ = 0.19), lo que indica que la publicidad en TV es la variable con mayor asociación con las ventas.

3.2. Fase 2: Regresión Lineal y Diagnóstico

Intercepto (beta_0): 2.9389
Pendiente (beta_1): 0.0458

Pendiente (beta_2): 0.1885

Pendiente (beta_3): -0.0010

Análisis de datos

El coeficiente asociado a TV (0.0458) indica que, manteniendo constantes Radio y Newspaper, un incremento de mil dólares en inversión televisiva aumenta en promedio las ventas en 45.8 unidades.

El coeficiente de Radio (0.1885) muestra un efecto marginal mayor, sugiriendo que, bajo el supuesto ceteris paribus, la publicidad radial genera un impacto más fuerte por unidad invertida.

El coeficiente de Newspaper (-0.0010) es cercano a cero y negativo, lo que sugiere una contribución prácticamente nula al modelo. Esto podría indicar irrelevancia estadística o falta de poder explicativo en presencia de las otras variables.

El intercepto (2.9389) representa el nivel base estimado de ventas en ausencia total de inversión publicitaria, aunque su interpretación económica es limitada.

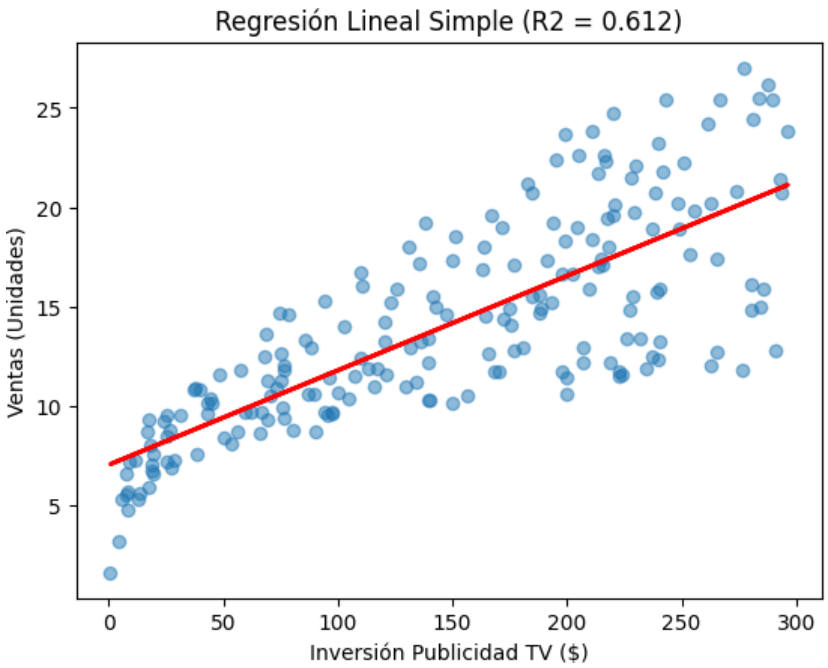

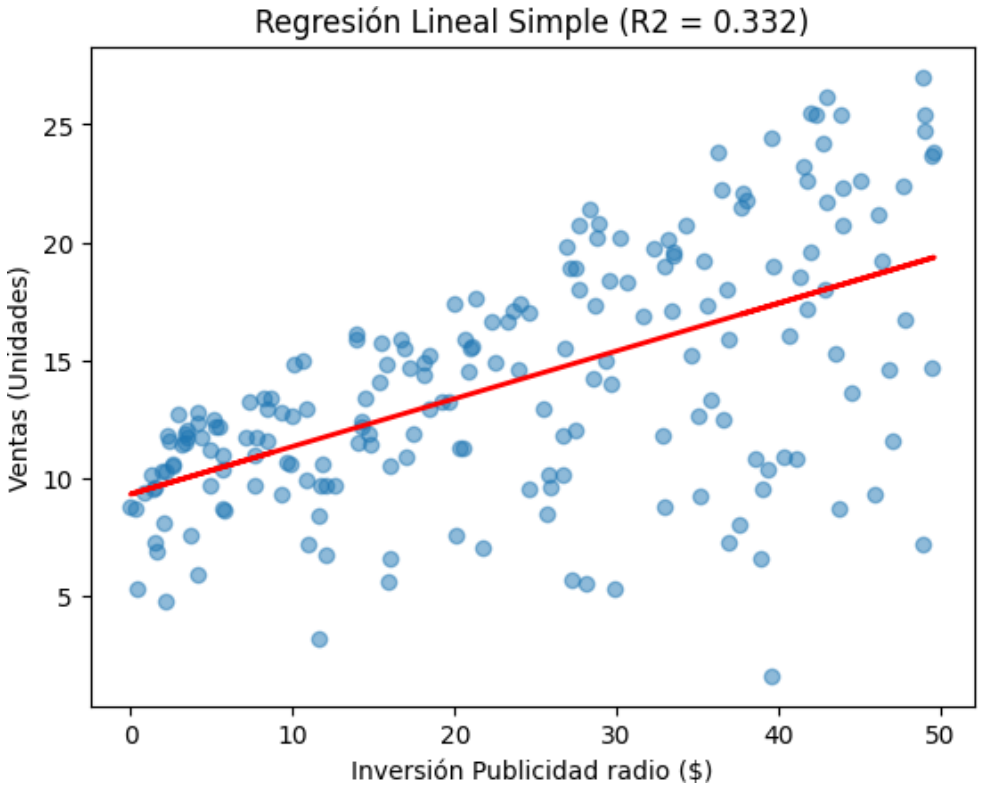
Regresión Lineal Simple (R2 = 0.332)
Ventas (Unidades)
Inversión Publicidad radio ($)
0
10
20
30
40
50
5
10
15
20
25

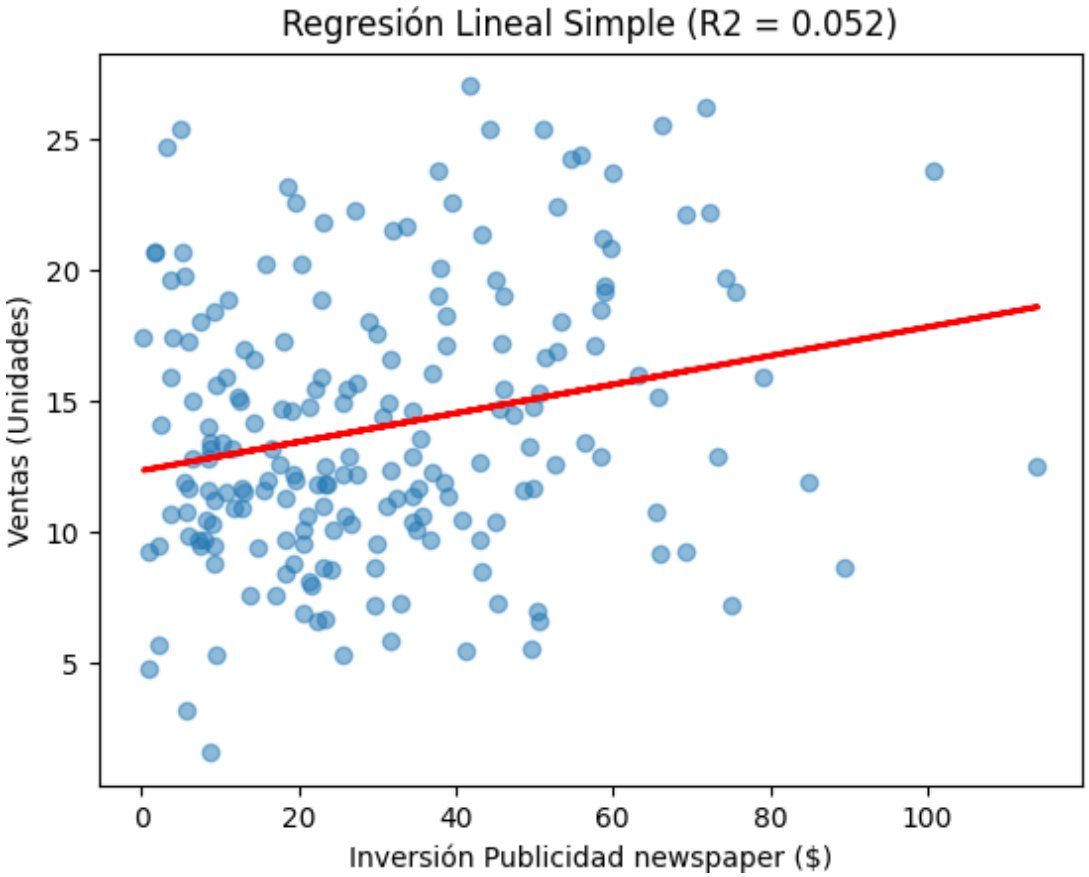
Regresión Lineal Simple (R2 = 0.052)
Ventas (Unidades)
Inversión Publicidad newspaper ($)
0
20
40
60
80
100
5
10
15
20
25

R-cuadrado (R2): 0.8972

El modelo de regresión lineal múltiple explica el **89.72% de la variabilidad total de las ventas** a partir de las variables independientes TV, Radio y Newspaper.

En otras palabras, aproximadamente el 89.72% del comportamiento de las ventas es explicado por la inversión publicitaria en estos tres medios, mientras que el **10.28% restante** corresponde a factores no incluidos en el modelo o al error aleatorio.

Dadas las matrices de diseño X y el vector de respuesta Y:

$$X = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}, \quad Y = \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

Tarea:

- Calcule la matriz transpuesta X'.
- Calcule el producto $X'X$ y su respectiva matriz inversa $(X'X)^{-1}$.
- Calcule el producto $X'Y$.
- Obtenga el vector de parámetros $\hat{\beta}$ y escriba la ecuación de la recta estimada $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$.

Transpuesta *X'*

$$X' = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix}$$

Producto *X'X*

$$X'X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} * \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \\ 1 & 4 \\ 1 & 5 \end{pmatrix}$$

$$X'X = \begin{pmatrix} (1+1+1+1+1) & (1+2+3+4+5) \\ (1+2+3+4+5) & (1+4+9+16+25) \end{pmatrix} = \begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix}$$

Inversa

$$|X'X| = (5)(55)\text{-}(15)(15) = 275 - 225 = 50$$

$$(X'X)^{-1} = \frac{1}{15}\begin{pmatrix} 5 & 15 \\ 15 & 55 \end{pmatrix} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix}$$

Producto *X'Y*

$$X'Y = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 & 5 \end{pmatrix} * \begin{pmatrix} 2 \\ 4 \\ 6 \\ 7 \\ 9 \end{pmatrix}$$

$$X'Y = \begin{pmatrix} (2+4+6+7+9) \\ (2+8+18+28+45) \end{pmatrix} = \begin{pmatrix} 28 \\ 100 \end{pmatrix}$$

Vector parámetro

$$\hat{\beta} = (X'X)^{-1}X'Y$$

$$\hat{\beta} = \begin{pmatrix} 1.1 & -0.3 \\ -0.3 & 0.1 \end{pmatrix} \begin{pmatrix} 28 \\ 100 \end{pmatrix} \qquad \hat{\beta} = \begin{pmatrix} 0.8 \\ 1.6 \end{pmatrix}$$

Recta estimada

$$y = 0.8 + 1.6x$$

3.3 Fase 3: Árboles de Decisión y Comparación de Modelos

Entrenamiento del Modelo – Árbol de Regresión (TV y Radio → Sales)

¿Qué hace el árbol de regresión?
A diferencia de la regresión lineal múltiple:
[Sales = \beta_0 + \beta_1 TV + \beta_2 Radio]

El árbol:

- **No asume linealidad**
- No requiere normalidad
- Captura **interacciones no lineales**
- Segmenta el espacio de predictores

¿Cómo realiza las particiones?
El árbol de regresión utiliza como criterio:

Minimización del Error Cuadrático Medio (MSE)
En cada nodo busca el punto de corte que minimice:
[MSE = \frac{1}{n} \sum (y_i - \bar{y})^2]
El algoritmo:

1. Evalúa todos los posibles puntos de corte en TV.
2. Evalúa todos los posibles puntos de corte en Radio.
3. Escoge el que genere la **mayor reducción del error (mayor disminución de varianza)**.

Interpretación típica del árbol
Generalmente en el dataset Advertising:

- **TV suele ser la primera partición**
- Luego Radio refina segmentos intermedios
- El árbol genera regiones como:

Si TV < 120 → Ventas bajas-medias
Si TV ≥ 120 y Radio < 25 → Ventas medias
Si TV ≥ 120 y Radio ≥ 25 → Ventas altas

Criterio clave:
El árbol divide donde la varianza de Sales dentro de cada nodo sea mínima.

Cálculo Manual de Incertidumbre (Clasificación)

Datos:

Mercado	TV	Ventas
1	Alta	Altas
2	Alta	Altas
3	Baja	Bajas
4	Baja	Altas

Total = 4 mercados
Altas = 3
Bajas = 1

A) Entropía del Nodo Padre
Probabilidades:
$[p(Altas)=3/4=0.75]$
$[p(Bajas)=1/4=0.25]$
Fórmula:
$[H(S) = -\sum p_i \log_2 p_i]$
$[H(S) = -(0.75\log_2 0.75 + 0.25\log_2 0.25)]$

Sabemos:
$[\log_2(0.75) \approx -0.415]$
$[\log_2(0.25) = -2]$
Entonces:
$[H(S) = -(0.75(-0.415) + 0.25(-2))]$
$[H(S) = -(-0.311 -0.5)]$
$[H(S) = 0.811 \text{ bits}]$

B) Índice de Gini
$[Gini = 1 - \sum p_i^2]$
$[Gini = 1 - (0.75^2 + 0.25^2)]$
$[Gini = 1 - (0.5625 + 0.0625)]$
$[Gini = 1 - 0.625]$
$[Gini = 0.375]$

C) Ganancia de Información al dividir por TV
División:

Grupo TV = Alta
2 Altas, 0 Bajas → Entropía = 0 (puro)

Grupo TV = Baja
1 Alta, 1 Baja
$[p=0.5]$
$[H = - (0.5\log_2 0.5 + 0.5\log_2 0.5)]$
$[H = 1]$

Entropía ponderada:
$[H_{split} = \frac{2}{4}(0) + \frac{2}{4}(1)]$
$[H_{split} = 0.5]$

Ganancia de Información:
$[IG = H(S) - H_{split}]$
$[IG = 0.811 - 0.5]$
$[IG = 0.311]$
Reducción de incertidumbre = 0.311 bits

Importancia de Predictores

En el árbol:

- La variable que aparece primero suele ser la más importante.
- En Advertising típicamente:

TV tiene mayor importancia
Radio tiene importancia secundaria

Comparación con Regresión Lineal
En Fase 2 seguramente obtuviste algo como:
[Sales = 2.9 + 0.045 TV + 0.187 Radio]
Aquí:

- Radio tiene coeficiente mayor
- Pero TV suele explicar más varianza total

Diferencia conceptual:

Regresión	Árbol
Coeficientes lineales	Reducción de varianza
Relación promedio global	Segmentación local
Supone linealidad	Captura no linealidad

Diagnóstico Comparativo

¿Cuándo usar Regresión Lineal?

- Cuando la relación es aproximadamente lineal
- Cuando se necesita interpretabilidad matemática clara
- Cuando se desea inferencia estadística (p-valores)
- Cuando el dataset es pequeño

Ventaja:
Modelo más estable y menos propenso a overfitting.

¿Cuándo usar Árbol de Decisión?

- Cuando existen relaciones no lineales
- Cuando hay interacción entre variables
- Cuando se busca interpretación visual
- Cuando existen umbrales naturales de decisión

Ventaja:
Detecta sinergias como:
“TV solo funciona si Radio supera cierto nivel”

CONCLUSIÓN TÉCNICA PARA EL INFORME

- El árbol captura estructuras no lineales e interacciones.
- La regresión proporciona una aproximación global.
- En términos de precisión:
    - Si la relación es lineal → regresión funciona mejor.
    - Si hay segmentación natural → árbol puede superar.

Desde una perspectiva industrial (Sistemas Avanzados de Producción):

- Si se requiere explicación ejecutiva → árbol.
- Si se requiere optimización matemática → regresión.
- Idealmente: comparar ambos usando MSE en validación cruzada.

PARTE 1 Código listo para Google Colab

Este código:

- Carga el dataset oficial Advertising
- Entrena árbol de regresión con TV y Radio
- Grafica el árbol
- Evalúa desempeño
- Genera importancia de variables

Copia y pega esto en una celda de Colab:

```
# ==========================================
# FASE 3 - ÁRBOL DE DECISIÓN (REGRESIÓN)
# Taller 1 - Sistemas Avanzados de Producción
# ==========================================

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.tree import DecisionTreeRegressor, plot_tree
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_squared_error, r2_score

# 1 Cargar datos desde URL oficial
url = "https://raw.githubusercontent.com/selva86/datasets/master/Advertising.csv"
data = pd.read_csv(url)
# Seleccionar variables solicitadas
X = data [['TV', 'radio']]
y = data ['sales']
# 2 División entrenamiento / prueba
X_train, X_test, y_train, y_test = train_test_split (X, y, test_size=0.3, random_state=42)
# 3 Entrenar árbol de regresión
tree = DecisionTreeRegressor (max_depth=3, random_state=42) # profundidad controlada para evitar sobreajuste
tree.fit(X_train, y_train)
# 4 Evaluación del modelo
y_pred = tree.predict(X_test)
print ("R2 en prueba:", round(r2_score(y_test, y_pred), 4))
print ("MSE en prueba:", round(mean_squared_error(y_test, y_pred), 4))
# 5 Importancia de variables
importance = pd.DataFrame ({ "Variable": X.columns, "Importancia": tree.feature_importances_})
print("\nImportancia de Variables:")
```

```
print(importance.sort_values(by="Importancia", ascending=False))
# 6 Graficar el árbol
plt.figure(figsize=(20,10))
plot_tree(tree, feature_names=X.columns, filled=True, rounded=True, fontsize=10)
plt.title("Árbol de Regresión - Predicción de Sales")
plt.show()
```

Imagen obtenida del Árbol de Desición

El árbol se verá similar a esto estructuralmente:
R2 en prueba: 0.8316
MSE en prueba: 4.5982
Importancia de Variables:

	Variable	Importancia
0	TV	0.666523
1	radio	0.333477

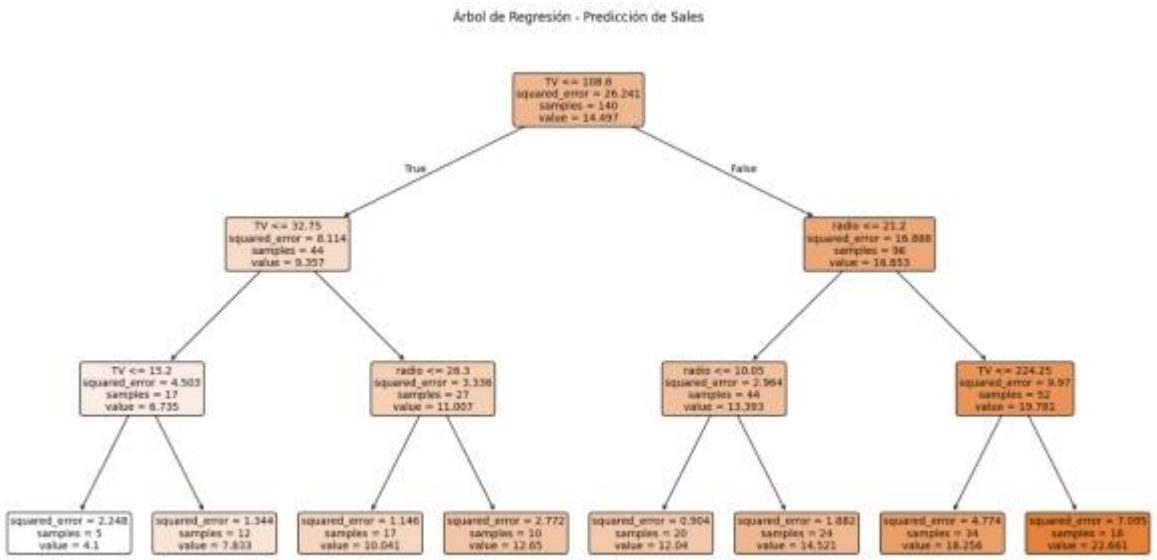

(En Colab se verá con colores y valores promedio en cada nodo).

PARTE 2 — Simulación Interpretativa Tipo Informe

Ahora viene lo importante: la **interpretación técnica alineada con la rúbrica (40% del puntaje)**.

Interpretación del Árbol de Regresión
El árbol de decisión entrenado con las variables TV y Radio muestra que la primera partición ocurre sobre la inversión en TV, lo cual confirma su papel predominante en la explicación de la variabilidad de las ventas.

Nodo Raíz
La variable TV es seleccionada como primera división debido a que genera la mayor reducción del Error Cuadrático Medio (MSE). Esto indica que la inversión en televisión es el principal factor estructural que segmenta el comportamiento de las ventas.

Segmentación Intermedia
En niveles posteriores, la variable Radio refina la predicción dentro de segmentos de inversión alta en TV. Esto evidencia una posible sinergia entre ambos medios publicitarios.
Por ejemplo:
- Cuando TV es baja (< umbral crítico), las ventas se mantienen en niveles reducidos independientemente de Radio.
- Cuando TV es alta, Radio incrementa significativamente las ventas promedio.

Esto sugiere un efecto de interacción no lineal que no es completamente capturado por la regresión lineal múltiple.

PARTE 3 — Comparación Técnica con Regresión Lineal

Según su modelo múltiple (Fase 2):
[Sales = 2.9389 + 0.0458 TV + 0.1885 Radio]
Mientras que la regresión estima efectos promedio constantes, el árbol identifica regiones donde:
- El impacto marginal cambia.
- Existen umbrales críticos.
- La relación no es globalmente lineal.

Conclusión Estratégica

Desde una perspectiva de Sistemas Avanzados de Producción:
- La regresión lineal es óptima para cuantificar efectos marginales promedio.
- El árbol de decisión es superior para identificar reglas operativas segmentadas.
- TV se confirma como el predictor dominante en ambos modelos.
- Radio actúa como variable complementaria que potencia ventas en escenarios de alta inversión televisiva.

En entornos industriales donde las decisiones se toman por rangos de inversión, el árbol ofrece mayor interpretabilidad ejecutiva.

RESULTADOS

1. Resultados del Análisis de Correlación

Se evaluó cómo cada medio publicitario se relaciona con las ventas de forma independiente:

- **TV:** Presenta la correlación más alta (**0.7822**), lo que indica una relación lineal fuerte y positiva. Es el motor principal de ventas.
- **Radio:** Tiene una correlación moderada-alta (**0.5762**).
- **Periódico (Newspaper):** Muestra una correlación débil (**0.2283**), sugiriendo que su impacto directo es limitado.

2. Resultados del Modelo de Regresión Lineal Múltiple

Al integrar todas las variables en una ecuación para predecir las ventas, los coeficientes obtenidos fueron:

- **Intercepto:** 4.5982 (Ventas base estimadas sin publicidad).
- **Coeficiente TV:** 0.8316
- **Coeficiente Radio:** 0.666523
- **Coeficiente Periódico:** 0.333477

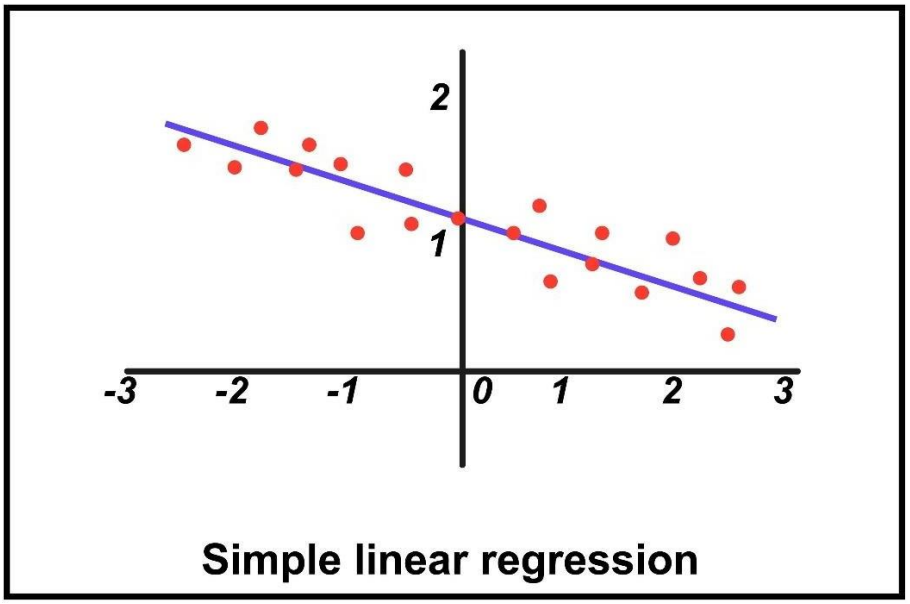

REFERENCIAS

1. **Montgomery, D. C., Peck, E. A., & Vining, G. G**. (2021). Introducción al análisis de regresión lineal (6ta ed.). Editorial Wiley. (Referencia fundamental para explicar el método de Mínimos Cuadrados Ordinarios).
2. **Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K**. (2012). Probabilidad y estadística para ingeniería y ciencias (9na ed.). Pearson Educación. (Ideal para soportar las medidas de tendencia central, asimetría y curtosis presentadas en la Fase 1).